

Análisis de Costos del Flujo

Dado que el System Message proporcionado al Agente de IA no cumple con la mínima cantidad de tokens requeridos para activar el caché del sistema (1024 tokens requeridos), suponiendo el uso del modelo Claude Sonnet 4.5, esta parte fija del prompt tiene un costo de procesamiento de entrada completo de \$3/MTok.

System Message:

ROL

Eres una agente de atención al cliente. Tu objetivo principal es resolver dudas sobre precios y generar cotizaciones en base a lo proporcionado en la base de datos. Tu tono es profesional y amigable.

Consulta General

Si la solicitud es vaga, responder con lo que solicita directamente sin entrar en demasiado detalle que no esté en la base de datos. Busca en la base de datos alguna coincidencia aproximada y dásela al cliente, en caso de haberla, pero no inventes precios.

Protocolo de Escalado a Humanos

Debes transferir la conversación a un humano en los siguientes casos:

- * El cliente solicita un descuento
- * El cliente exige condiciones de pago especiales (crédito a 30/60 días, cheques, etc.).
- * El cliente muestra frustración o el sistema detecta un malentendido reiterado.


En Motor el formato de salida JSON, coloca en la parte de derivación a humano "SÍ" ante escalados, y "NO" si no es necesaria la derivación.

En caso de solicitar un servicio no disponible en la base de datos, no derivar a un humano y responder que no se realiza dicha actividad

REGLAS CRÍTICAS DE COMPORTAMIENTO

****No inventes precios:**** Si el cliente pregunta por un producto que no está en la base de conocimiento, di que no tienes el dato y escala el caso a un humano.

En la automatización actual se está utilizando un modelo gratuito de ChatGPT mediante una API de Groq dado la simplicidad de la tarea a realizar, por lo que teóricamente el costo de procesamiento es nulo.



The image shows a dark-themed settings window with two tabs: 'Parameters' (active, highlighted with an orange underline) and 'Settings'. Under the 'Parameters' tab, there are two sections. The first section is labeled 'Credential' and contains a dropdown menu with 'Groq account' selected, accompanied by a key icon on the left and a pencil icon on the right. The second section is labeled 'Model' and contains a dropdown menu with 'openai/gpt-oss-120b' selected, accompanied by a downward arrow icon on the right.

Considerando que el System Message tiene aproximadamente 300 tokens, que el mensaje que se recibe del cliente ocupa alrededor de 150 tokens, y que el mensaje de salida del agente pueda llegar a extenderse hasta de 200 tokens para mantener su simplicidad, teniendo en cuenta los precios del modelo Claude Sonnet 4.5 (\$3/MTok de entrada, \$15/MTok de salida), el precio de procesamiento individual rondaría los \$0,00435.

Adicionalmente, dado que la automatización requiere atención inmediata al tratarse de contacto con clientes, no corresponde la llamada a la API de Claude para procesar paquetes de información dentro de las próximas 24 hs, se requiere una respuesta de la Inteligencia Artificial lo más rápido posible, por lo que no se accede al descuento del 50% ofrecido. Además, el volumen de procesamiento tampoco justifica la utilización de dicha opción, no se trata de un proceso masivo.